

DOCUMENTACION TECNICA

# Runbook: puente Hermes

ESP32-S3 Zero

---

RUNBOOK-HERMES-BRIDGE.MD

# Runbook: puente Hermes — ESP32-S3 Zero

## TABLA DE CONTENIDOS


|                                                     |    |
|-----------------------------------------------------|----|
| Runbook: puente Hermes — ESP32-S3 Zero .....        | 2  |
| Descripcion general.....                            | 2  |
| Flujo de operacion final .....                      | 3  |
| Requisitos previos .....                            | 3  |
| Paso 1 — Habilitar la API de Hermes .....           | 3  |
| Paso 2 — Fijar la IP de la Mac mini .....           | 4  |
| Paso 3 — Instalar el puente .....                   | 4  |
| Paso 4 — Descargar la voz de Piper (español) .....  | 5  |
| Paso 5 — Probar el puente manualmente .....         | 5  |
| Variables de configuracion (todas opcionales) ..... | 6  |
| Paso 6 — Firmware: IP y flasheo .....               | 6  |
| Paso 7 — Verificacion end-to-end.....               | 7  |
| Paso 8 — Dejarlo como servicio (launchd) .....      | 8  |
| VoiceHistory y contexto Telegram .....              | 8  |
| Rollback a la nube de Elato.....                    | 8  |
| Solucion de problemas.....                          | 10 |
| Referencia rapida .....                             | 11 |

## Descripcion general

Procedimiento completo para poner en marcha el **puente ElatoAI ↔ Hermes**: el ESP32-S3 Zero deja de hablar con la nube de Elato y pasa a usar un servidor local (Mac mini) que transcribe con faster-whisper, consulta al agente **Hermes** y sintetiza voz con Piper. Este runbook esta escrito para que **cualquier agente o persona** pueda ejecutarlo de principio a fin.

**NOTA** El codigo del puente ya existe en `server/hermes-bridge/bridge.py` y el firmware ya esta cambiado a `DEV_MODE` (commit correspondiente). Lo que queda es la instalacion en la Mac mini y ajustar la IP. El diseño y sus razones estan en `[[propuesta-hermes-bridge]]`.

## Flujo de operacion final



El pipeline usa **LLM en modo streaming**: el puente empieza a sintetizar voz al recibir la primera frase completa del modelo (boundary en `.!?\n`), sin esperar la respuesta entera. La latencia percibida es mucho menor que en la version inicial.

## Requisitos previos

- Mac mini con **Hermes instalado y funcionando** (`hermes_gateway` arranca).
- Homebrew y Python 3.10+ en la Mac mini.
- El repo ElatoAI clonado o copiado en la Mac mini (basta `server/hermes-bridge/`).
- El ESP32-S3 Zero con su montaje validado (ver `[[conexionado-por-componente]]`).
- Un equipo con PlatformIO para reflashear el firmware (paso 6).

## Paso 1 — Habilitar la API de Hermes

En la Mac mini, editar `~/hermes/.env` y añadir:

```
API_SERVER_ENABLED=true
API_SERVER_KEY=elige-una-clave-secreta
```

Reiniciar el gateway y comprobar que aparece la linea del API server:

```
hermes gateway
# esperado en el log: [API Server] API server listening on http://127.0.0.1:8642
```

Verificar con curl:

```
curl http://localhost:8642/v1/chat/completions \
-H "Authorization: Bearer elige-una-clave-secreta" \
-H "Content-Type: application/json" \
-d '{"model":"hermes-agent","messages":[{"role":"user","content":"hola"}]}'
```

**ADVERTENCIA** La API de Hermes da acceso a todo su toolset (incluida la terminal). **No cambiar** `API_SERVER_HOST` de su valor por defecto (`127.0.0.1`): el puente corre en la misma maquina y no necesita que Hermes escuche en la red.

---

## Paso 2 — Fijar la IP de la Mac mini

El firmware apunta a la IP que le pases al compilar en la variable de entorno `HERMES_SERVER_IP` (ver Paso 6). Reservar esa IP para la Mac mini en el router (reserva DHCP) para que nunca cambie.

```
# En la Mac mini, para conocer la IP actual:
ipconfig getifaddr en0 || ipconfig getifaddr en1
```

---

## Paso 3 — Instalar el puente

```
cd <repo>/server/hermes-bridge
brew install opus # libopus, requerido por opuslib
python3 -m venv .venv
.venv/bin/pip install -r requirements.txt
```

El directorio incluye `voice_history.py` (stub funcional). El puente arranca con el, aunque sin persistencia ni contexto Telegram. Ver seccion "VoiceHistory y contexto Telegram" mas abajo si se quiere la version completa.

## Paso 4 — Descargar la voz de Piper (español)

```
mkdir -p ~/piper-voices && cd ~/piper-voices
curl -LO https://huggingface.co/rhasspy/piper-voices/resolve/main/es/es_ES/davefx/medium/es_ES-davefx-medium.onnx
curl -LO https://huggingface.co/rhasspy/piper-voices/resolve/main/es/es_ES/davefx/medium/es_ES-davefx-medium.onnx
```

**TIP** Cualquier voz de `rhasspy/piper-voices` sirve (hay varias en español). Si se usa otra, ajustar `PIPER_VOICE` en el paso 5. El `.onnx.json` es obligatorio: el puente lee de ahí el sample rate.

## Paso 5 — Probar el puente manualmente

```
cd <repo>/server/hermes-bridge
HERMES_API_KEY=elige-una-clave-secreta \
PIPER_VOICE=~/.piper-voices/es_ES-davefx-medium.onnx \
.venv/bin/python3 bridge.py
```

Salida esperada (la primera vez tarda ~2 s: carga el modelo Whisper):

```
... Loading faster-whisper model 'base'...
... Whisper model loaded in 1.8s
... Bridge ready: ws://0.0.0.0:8000/ token http://0.0.0.0:3000/api/generate_auth_token
... Hermes endpoint: http://127.0.0.1:8642/v1/chat/completions (model hermes-agent)
... Whisper model: base | Piper voice: /Users/.../es_ES-davefx-medium.onnx
```

Verificar los endpoints desde otra maquina de la LAN:

```
# Token
curl "http://$HERMES_SERVER_IP:3000/api/generate_auth_token?macAddress=TEST"
# esperado: {"token": "elato-local-token"}

# Health (nuevo en version de produccion)
curl http://$HERMES_SERVER_IP:3000/health
curl http://$HERMES_SERVER_IP:8000/health
# esperado: {"status": "ok"}
```

Log por turno de conversacion (nuevo en version de produccion):

```
User: hola como estas
Hermes: Bien, gracias. ¿En qué te puedo ayudar? | STT=0.4s first_token=1.2s chunks=2
```

## Variables de configuracion (todas opcionales)

| Variable                             | Default                                                | Uso                                                                                              |
|--------------------------------------|--------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| <code>HERMES_API_KEY</code>          | (vacía)                                                | La <code>API_SERVER_KEY</code> de Hermes                                                         |
| <code>HERMES_URL</code>              | <code>http://127.0.0.1:8642/v1/chat/completions</code> | Endpoint LLM                                                                                     |
| <code>HERMES_TIMEOUT_S</code>        | <code>60</code>                                        | Timeout máximo entre tokens del stream SSE                                                       |
| <code>WHISPER_MODEL</code>           | <code>base</code>                                      | Modelo STT ( <code>base</code> = rápido, <code>small</code> / <code>medium</code> = más preciso) |
| <code>PIPER_VOICE</code>             | <code>~/piper-voices/es_ES-davefx-medium.onnx</code>   | Voz TTS                                                                                          |
| <code>BRIDGE_LANGUAGE</code>         | <code>es</code>                                        | Idioma para Whisper                                                                              |
| <code>BRIDGE_SYSTEM_PROMPT</code>    | (prompt en español)                                    | Personalidad del asistente                                                                       |
| <code>VAD_SILENCE_MS</code>          | <code>800</code>                                       | Silencio que cierra la frase                                                                     |
| <code>VAD_AGGRESSIVENESS</code>      | <code>1</code>                                         | Sensibilidad del VAD (0-3; subir si corta frases a mitad)                                        |
| <code>BRIDGE_AUTH_TOKEN</code>       | <code>elato-local-token</code>                         | Token devuelto al ESP32 (no se valida)                                                           |
| <code>BRIDGE_MAX_HISTORY</code>      | <code>20</code>                                        | Mensajes de historial que se mantienen en memoria                                                |
| <code>BRIDGE_TELEGRAM_CONTEXT</code> | <code>5</code>                                         | Mensajes de Telegram inyectados como contexto (requiere VoiceHistory completo)                   |

## Paso 6 — Firmware: IP y flasheo

El firmware ya está en `DEV_MODE` + `VOICE_SERVER_DENO`. La IP de la Mac mini **no está escrita en el código**: se inyecta al compilar desde la variable de entorno `HERMES_SERVER_IP` (lo hace `firmware-arduino/scripts/hermes_server_ip.py`, registrado como `extra_scripts` en `platformio.ini`).

```
export HERMES_SERVER_IP=192.168.1.100 # <- la IP reservada de tu Mac mini
```

Conviene dejarlo en el `~/ .bashrc` (o `~/ .zshrc`) del equipo que compila, así no hay que acordarse en cada build. Si la IP cambia, se recompila con el nuevo valor: no hay que tocar `Config.cpp`.

**AVISO:** si `HERMES_SERVER_IP` no está definida, el build **no falla** pero usa el placeholder `192.168.1.100` de `Config.cpp` y el firmware no va a encontrar el puente. El script lo avisa en la salida de `pio run`: `[hermes] AVISO: HERMES_SERVER_IP no está definida...`

Compilar y flashear (el Zero necesita `--no-stub`, ya configurado; detalles en `[[firmware-binarios-y-flasheo]]`):

```
cd firmware-arduino
pio run -t upload --upload-port /dev/ttyACM0
```

**NOTA** El token de Elato guardado en NVS no estorba: en `DEV_MODE` el firmware pide un token nuevo al puente solo si NVS está vacío, y el puente acepta cualquier token (no valida el header). No hace falta borrar NVS.

## Paso 7 — Verificación end-to-end

1. Con el puente corriendo, encender el ESP32.
2. **Log del puente:** debe aparecer `Token request from MAC B8:F8:62:D7:59:C4` y luego `Device connected (MAC ...)`.
3. **LED:** verde/amarillo (escuchando) tras el arranque.
4. **Hablar** una frase corta y callar: el puente muestra `User: <texto>` y el altavoz responde antes de que Hermes termine (streaming). El log muestra `STT=Xs first_token=Xs chunks=N` al finalizar el turno.
5. El **botón KY-004** sigue funcionando igual (dormir/despertar).

Monitor serie del ESP32 (opcional): `[WSc] Connected to url: /`, luego `AUDIO.COMMITTED` / `RESPONSE.CREATED` / `RESPONSE.COMPLETE` en cada turno. `RESPONSE.CREATED` aparece varias veces por turno (una por frase sintetizada).

## Paso 8 — Dejarlo como servicio (launchd)

```
cd <repo>/server/hermes-bridge
# 1. Editar com.elato.hermes-bridge.plist: rutas reales del venv/repo,
#   HERMES_API_KEY y PIPER_VOICE (buscar "AJUSTAR").
cp com.elato.hermes-bridge.plist ~/Library/LaunchAgents/
launchctl load ~/Library/LaunchAgents/com.elato.hermes-bridge.plist
# logs:
tail -f /tmp/hermes-bridge.log
```

Con `KeepAlive` el puente se reinicia solo si se cae, y arranca al encender la Mac mini. El ESP32 reintenta la conexión WebSocket cada 1 s automáticamente, así que un reinicio del puente se recupera sin tocar la placa.

Para detenerlo limpiamente (el bridge registra la señal en el log):

```
launchctl stop com.elato.hermes-bridge # lo detiene; KeepAlive lo relanza
launchctl unload ~/Library/LaunchAgents/com.elato.hermes-bridge.plist # lo desactiva
```

## VoiceHistory y contexto Telegram

El repo incluye `voice_history.py` como stub funcional: el puente arranca y conversa normalmente, pero sin persistencia ni integración con Telegram.

La implementación completa (disponible en la Mac mini de DebBot) añade: - Persistencia del historial de conversación por MAC del dispositivo. - `get_telegram_context()`: inyecta los últimos N mensajes del canal de Telegram al historial antes de consultar a Hermes, de modo que el asistente de voz sabe lo que se habló en ese canal.

Para activarla, sustituir `voice_history.py` por la versión completa de DebBot. La variable `BRIDGE_TELEGRAM_CONTEXT` controla cuantos mensajes se inyectan (default 5; poner 0 para desactivar aunque el módulo completo esté instalado).

## Rollback a la nube de Elato

En `firmware-arduino/src/Config.h`, invertir los defines y reflashear:



```
// #define DEV_MODE
#define ELATO_MODE
...
// #define VOICE_SERVER_DENO
#define VOICE_SERVER_CLOUDFLARE
```

Nada mas: los certificados y URLs de Elato siguen intactos en `Config.cpp`. Tambien existe el respaldo `~/Firmware_ELATO_ok_limpio_merged.bin` (ver [\[\[firmware-binarios-y-flasheo\]\]](#)) que restaura la placa completa a la configuracion Elato con un solo comando.

---

## Solucion de problemas

| Sintoma                                            | Causa probable                                                    | Solucion                                                                                           |
|----------------------------------------------------|-------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
| <code>Piper voice not found</code> al arrancar     | Falta la voz o la ruta es otra                                    | Paso 4; ajustar <code>PIPER_VOICE</code>                                                           |
| <code>Hermes HTTP 401</code> en el log             | <code>HERMES_API_KEY</code> no coincide                           | Usar la misma <code>API_SERVER_KEY</code> de <code>~/hermes/.env</code>                            |
| <code>Hermes HTTP</code> con connection refused    | Hermes no corre o API no habilitada                               | Paso 1; <code>hermes gateway</code> activo                                                         |
| El ESP32 no pide token                             | IP mal puesta en <code>Config.cpp</code> o firewall               | Verificar paso 6 y el firewall de macOS (permitir Python)                                          |
| Conecta pero nunca transcribe                      | VAD no detecta voz o ruido de fondo alto                          | Bajar <code>VAD_AGGRESSIVENESS</code> a 0 o subir a 2; revisar el micro                            |
| Transcribe frases vacias                           | Doble-VAD (no deberia ocurrir con <code>vad_filter=False</code> ) | Verificar que se usa la version de produccion del bridge                                           |
| El altavoz corta a mitad de la primera frase       | <code>VAD_SILENCE_MS</code> demasiado bajo                        | Subir <code>VAD_SILENCE_MS</code> a 1000                                                           |
| Audio entrecortado en el altavoz                   | CPU saturada; pacing roto                                         | Cerrar cargas pesadas; usar <code>WHISPER_MODEL=base</code>                                        |
| <code>first_token</code> muy alto (>5 s) en el log | Hermes usa herramientas (agentico)                                | Configurar <code>model_routes</code> en Hermes para respuestas directas                            |
| <code>ImportError: opuslib</code>                  | Falta libopus                                                     | <code>brew install opus</code>                                                                     |
| <code>ModuleNotFoundError: voice_history</code>    | Falta el archivo stub                                             | Verificar que <code>voice_history.py</code> esta en el mismo directorio que <code>bridge.py</code> |
| WS se desconecta cada ~60 s                        | heartbeat no configurado (version antigua)                        | Usar la version de produccion ( <code>heartbeat=30.0</code> )                                      |
| El puente no registra la señal de parada           | Version antigua sin signal handlers                               | Usar la version de produccion                                                                      |

## Referencia rapida

### MAC MINI:

```
~/hermes/.env          -> API_SERVER_ENABLED=true, API_SERVER_KEY=...
server/hermes-bridge/  -> bridge.py + voice_history.py + requirements.txt + plist
~/piper-voices/        -> voz TTS (.onnx + .onnx.json)
puertos: 3000 (token+health), 8000 (WS+health), 8642 (Hermes, solo local)
```

### HEALTH CHECK:

```
curl http://$HERMES_SERVER_IP:3000/health -> {"status": "ok"}
curl http://$HERMES_SERVER_IP:8000/health -> {"status": "ok"}
```

### FIRMWARE (firmware-arduino/):

```
src/Config.h          -> #define DEV_MODE + #define VOICE_SERVER_DENO
IP del puente          -> env HERMES_SERVER_IP (inyectada al compilar)
flasheo                -> pio run -t upload --upload-port /dev/ttyACM0
```

### SERVICIO:

```
launchctl load ~/Library/LaunchAgents/com.elato.hermes-bridge.plist
launchctl stop com.elato.hermes-bridge # parada temporal (KeepAlive lo relanza)
launchctl unload ~/Library/LaunchAgents/com.elato.hermes-bridge.plist # desactivar
tail -f /tmp/hermes-bridge.log
```

### LOG POR TURNO:

```
User: <texto>
Hermes: <respuesta> | STT=0.4s first_token=1.2s chunks=2
```

ROLLBACK: Config.h -> ELATO\_MODE + VOICE\_SERVER\_CLOUDFLARE y reflashear.